



Campus Irapuato-Salamanca | División de Ingenierías

Propuesta de tesis

“Búsqueda de vacíos estables en teoría de cuerdas mediante métodos metaheurísticos”

Presentado por: **Brandon Marquez Salazar**
b.marquezsalar@ugto.mx

Alumno dentro del programa de Maestría en Ingeniería Eléctrica (Instrumentación y Sistemas Digitales)

 Dr. Ángel Díaz Pacheco
Asesor de Proyecto

 Dr. César Eduardo Damián Ascencio
Coasesor de Proyecto

Sinodales propuestos

- ✿ Dr. Carlos Hugo García Capulín
- ✿ Dr. Juan Pablo Ignacio Ramírez Paredes
- ✿ Dra. Dora Luz Almanza Ojeda
- ✿ Dr. Mario Alberto Ibarra Manzano
- ✿ Dr. Juan Carlos Gomez Carranza

Índice general

1	Introducción	2
1.1	Objetivos	2
1.1.1	Objetivo general	2
1.1.2	Objetivos específicos	3
1.2	Justificación	3
1.3	Antecedentes	4
1.4	Desarrollo	5
2	Cronograma	8
3	Resultados	8
4	Datos SECIHTI	9
4.1	Metas del proyecto	9
4.2	Impacto científico del proyecto	9
4.3	Aportación a problemas prioritarios	10
	Bibliografía	11

1 Introducción

El uso de herramientas computacionales ha tenido un impacto significativo dentro de la investigación científica [1]. Dicho impacto abarca desde el desarrollo de sistemas para la automatización y gestión de datos [2], hasta modernas aproximaciones de inteligencia artificial basada en tensores [3, 4], incluyendo técnicas de *Machine Learning* (ML) orientadas al modelado y análisis de sistemas complejos.

En este contexto, los métodos inspirados en la naturaleza (*Nature-Inspired Methods*, NIM) han emergido como herramientas computacionales eficientes para la resolución de problemas de optimización de alta complejidad, donde los métodos analíticos tradicionales resultan insuficientes o inaplicables. Estos algoritmos abstraen principios de sistemas naturales, como procesos evolutivos, dinámicas colectivas o interacciones físicas, para diseñar estrategias de búsqueda en espacios de soluciones de gran dimensionalidad [5, 6].

Las metaheurísticas, en particular, constituyen una clase de algoritmos de optimización estocástica que implementan reglas locales simples para inducir dinámicas globales complejas. Desde una perspectiva de ingeniería, su principal fortaleza radica en la capacidad de balancear mecanismos de exploración global del espacio de búsqueda con procesos de explotación local, permitiendo abordar funciones objetivo altamente no lineales, multimodales o sin expresión analítica explícita [5, 7].

En este sentido, la optimización puede entenderse como un problema de búsqueda eficiente dentro de un espacio de parámetros, donde el objetivo es identificar configuraciones que minimicen o maximicen una función de costo bajo restricciones específicas [8]. Cuando la evaluación de dicha función es computacionalmente costosa o su estructura es desconocida, los enfoques metaheurísticos proporcionan una alternativa robusta frente a métodos deterministas basados en gradientes.

Un caso representativo de este tipo de problemas se encuentra en la exploración de paisajes de soluciones (*string landscape*) derivados de la teoría de cuerdas. Desde una perspectiva computacional, este problema puede formularse como la optimización de una función potencial en un espacio de alta dimensionalidad, caracterizado por la presencia de múltiples óptimos locales, regiones altamente no convexas y comportamiento numéricamente inestable.

Bajo estas condiciones, los métodos tradicionales presentan limitaciones significativas en términos de convergencia y costo computacional. En contraste, las metaheurísticas permiten explorar de manera eficiente el espacio de soluciones, incrementando la probabilidad de identificar configuraciones estables y reduciendo el número de evaluaciones necesarias de la función objetivo. Por ello, su implementación representa una estrategia adecuada para el análisis computacional de sistemas complejos en el contexto de la física teórica.

1.1 Objetivos

1.1.1 Objetivo general

Implementar métodos metaheurísticos para la optimización de los parámetros (flujos y coeficientes) de una función potencial derivada de modelos específicos de teoría de cuerdas, con el fin de identificar y caracterizar configuraciones de vacío

estables.

1.1.2 Objetivos específicos

- Analizar modelos derivados de teoría de cuerdas con énfasis en la estructura de la función potencial y la caracterización de vacíos estables.
- Identificar los parámetros relevantes (flujos y coeficientes) que intervienen en la definición del potencial efectivo y su impacto en la estabilidad de las soluciones.
- Revisar y seleccionar métodos metaheurísticos adecuados (algoritmos genéticos, optimización por enjambre de partículas, algoritmos de estimación de distribución, colonia de hormigas, entre otros) para el problema planteado.
- Formular el problema de optimización de la función potencial como un problema computacional en espacios de alta dimensionalidad.
- Implementar los métodos seleccionados y ajustar sus parámetros para su aplicación en el contexto del modelo físico considerado.
- Evaluar el desempeño de los métodos mediante métricas de convergencia, calidad de solución y capacidad para identificar vacíos estables.
- Comparar los resultados obtenidos con enfoques existentes o configuraciones base, con el fin de determinar mejoras en la exploración del espacio de soluciones.

1.2 Justificación

La exploración de configuraciones de vacío en teoría de cuerdas puede formularse como un problema de optimización en espacios de alta dimensionalidad, donde las funciones de energía potencial derivadas de modelos específicos presentan múltiples óptimos locales, regiones altamente no convexas y estructuras multimodales que dificultan la aplicación de métodos analíticos tradicionales o técnicas basadas en gradientes [9, 10]. En este contexto, las metaheurísticas ofrecen una alternativa computacional adecuada para abordar la búsqueda sistemática de configuraciones estables.

En optimización computacional, el teorema de *No Free Lunch* (NFL) establece que no existe un algoritmo universalmente superior para todos los problemas [11]. El desempeño relativo de los métodos depende de las propiedades específicas de la función objetivo y del espacio de búsqueda. Para el caso de funciones potenciales asociadas a modelos de teoría de cuerdas, no existe garantía *a priori* de que un método particular sea el más adecuado en términos de eficiencia, precisión o capacidad de exploración.

Por tanto, resulta pertinente explorar un conjunto amplio de metaheurísticas (algoritmos genéticos, optimización por enjambre de partículas, algoritmos de estimación de distribución, colonia de hormigas, entre otros) con el fin de evaluar su desempeño en la optimización de este tipo de problemas. La relevancia de este proyecto radica en el desarrollo de un análisis comparativo sistemático que permita

identificar estrategias de búsqueda más eficientes. En particular, se busca mejorar la capacidad de exploración del espacio de soluciones e incrementar la cantidad de vacíos estables identificados respecto a trabajos previos como [12], contribuyendo así a una caracterización más completa del paisaje de soluciones.

1.3 Antecedentes

El ámbito de la investigación de alto rigor, como el que caracteriza a la química o la cosmología, suele asociarse con métodos matemáticos formalmente fundamentados. Sin embargo, en las últimas décadas, los métodos metaheurísticos han irrumpido en estos campos con resultados notables. Su aplicación ha permitido demostrar que, a pesar de carecer de la formalidad matemática que tradicionalmente se exige en estas disciplinas, constituyen herramientas aplicables y, en muchos contextos, altamente efectivas [13, 14].

Esta efectividad se traduce en resultados concretos, como una reducción significativa del costo computacional y, cuando el modelo está adecuadamente parametrizado y la función objetivo correctamente definida, una mejora en la calidad de las soluciones gracias a sus capacidades de explotación. En algunos casos, estos métodos incluso superan el desempeño de enfoques tradicionales [15].

El uso de metaheurísticas para explorar el espacio de configuraciones en teoría de cuerdas ha demostrado mejoras significativas en términos de eficiencia, capacidad de descubrimiento y precisión en comparación con métodos de búsqueda aleatoria. A continuación, se presentan los principales avances, organizados según las propiedades que estas técnicas han evidenciado.

El trabajo pionero de Abel y Rizos [16] estableció que los algoritmos genéticos son órdenes de magnitud más eficientes que el muestreo aleatorio para localizar configuraciones con propiedades fenomenológicas específicas en modelos fermiónicos libres. Este resultado es relevante, ya que demuestra que, a pesar de que el espacio de búsqueda es inmenso (del orden de 2^{51} configuraciones posibles), la estructura del paisaje permite que métodos basados en selección y recombinación converjan rápidamente hacia regiones de interés.

Posteriormente, el trabajo de Bizet et al. [17] reportó más de sesenta mil configuraciones de flujo con puntos críticos en compactificaciones tipo IIB, empleando un algoritmo genético acoplado a una red neuronal. Este enfoque híbrido permitió reducir significativamente el costo computacional en comparación con métodos de fuerza bruta, evidenciando que la integración de metaheurísticas con técnicas de aprendizaje automático permite escalar la exploración a espacios de mayor complejidad.

Más allá de la búsqueda eficiente, las metaheurísticas han demostrado capacidad para generar configuraciones novedosas no reportadas previamente. He, Jejjala y Silva [18] utilizó templado simulado (*simulated annealing*) para construir *brane tilings* geoméricamente consistentes, logrando descubrir una nueva configuración con 26 campos cuánticos que no aparecía en catálogos exhaustivos previos. Este trabajo evidencia que las metaheurísticas no solo optimizan dentro de espacios conocidos, sino que también permiten explorar regiones inéditas del espacio de soluciones.

En el ámbito de la clasificación geométrica, [19] alcanzó precisiones superiores al 99.9% en la predicción de polítopos que conducen a orientifolds de Calabi-Yau y

vacíos Tipo IIB. Aunque su enfoque principal es una red neuronal convolucional, el proceso de entrenamiento y validación cruzada demuestra que los métodos computacionales pueden capturar patrones sutiles en los datos de entrada (las coordenadas de los politopos) y traducirlos en predicciones de alta calidad sobre la viabilidad de las configuraciones resultantes.

Un avance particularmente relevante para el problema de optimización de potenciales es el reportado por Lanza y Westphal [9]. Mediante técnicas de aprendizaje automático, los autores identificaron regiones de “penumbra” (zonas de transición entre el interior del espacio de módulos y sus límites asintóticos) en las que emergen configuraciones metaestables con energía positiva. Aunque su enfoque no es estrictamente metaheurístico, el trabajo demuestra que estas regiones albergan estructuras finas del potencial susceptibles de ser exploradas mediante métodos de optimización global.

Finalmente, De Luca [10] abordó el problema desde una perspectiva numérica distinta, mediante la resolución directa de ecuaciones diferenciales parciales utilizando redes neuronales. Si bien este enfoque no emplea metaheurísticas, su trabajo pone de manifiesto la necesidad de métodos computacionales robustos para abordar problemas geométricos en compactificaciones, y establece un punto de referencia frente a enfoques alternativos para la construcción de métricas y configuraciones de vacío.

Los trabajos mencionados evidencian una tendencia clara: el uso de metaheurísticas permite explorar de manera eficiente el paisaje de vacíos. En particular, Damian y Loaiza-Brito [12] implementó templado simulado para identificar más de 170 configuraciones dS estables en compactificaciones tipo IIB con torsión, demostrando la viabilidad del enfoque. No obstante, dicho estudio se limita al uso de un único algoritmo estocástico, lo que restringe la evaluación del desempeño relativo de distintas estrategias de optimización.

En este contexto, el presente trabajo propone extender este análisis mediante la implementación y comparación de un conjunto más amplio de metaheurísticas, con el objetivo de evaluar su desempeño relativo y determinar si es posible incrementar la cantidad de vacíos estables identificados respecto a lo reportado en Damian y Loaiza-Brito [12].

1.4 Desarrollo

El desarrollo del proyecto se ha estructurado en etapas que responden a los objetivos planteados y al cronograma establecido.

Análisis del modelo base. Se realizó ingeniería inversa del código original en Mathematica proporcionado por Damian y Loaiza-Brito [12], identificando la función potencial, sus descriptores (cuadrado del gradiente, matriz hessiana y autovalores), así como la lógica del método de optimización empleado originalmente (templado simulado con refinamiento mediante gradiente conjugado). Este análisis permitió extraer las expresiones simbólicas que definen el modelo.

Implementación simbólica en Python. Con base en las expresiones obtenidas, se desarrolló un módulo en Python utilizando `sympy` para definir la función poten-

Potential function		Jacobian matrix	
Python	Wolfram	i, j	
$\frac{A3N3}{\tau^3}$	$\frac{AO3}{\tau^3}$	1, 1	$\frac{3 AD_5}{4 s^{5/2} \tau^{5/2}}$
$\frac{AD_5}{\sqrt{s} \tau^{5/2}}$	$\frac{AD_5}{\sqrt{s} \tau^{5/2}}$		$\frac{3 AD_5 \sqrt{s} \sqrt{\tau}}{4 s^3 \tau^3}$
$\frac{AF_3}{s \tau^3}$	$\frac{AF_3}{s \tau^3}$	2, 1 & 1, 2	$\frac{2 AF_3}{s^3 \tau^3}$
$\frac{AF_5}{s \tau^4}$	$\frac{AF_5}{s \tau^4}$		$\frac{5 AD_5}{4 s^{3/2} \tau^{7/2}}$
$\frac{AH_3 s}{s \tau^3}$	$\frac{AH_3 s}{s \tau^3}$		$\frac{5 AD_5 \sqrt{\tau}}{s^{3/2} \tau^4}$
			$\frac{12 AF_3}{s^2 \tau^4}$
		2, 2	$-\frac{3 AH_3}{\tau^4}$
			$-\frac{12 AH_3}{4 \tau^4}$
			$\frac{12 A3N3}{\tau^5}$
			$\frac{1}{4s\tau^6} (48 AO3 s\tau)$
			$\frac{35 AD_5}{4\sqrt{s} \tau^{9/2}}$
			$\frac{1}{4s\tau^6} (35 AD_5 \sqrt{s} \tau^{3/2})$
			$\frac{12 AF_3}{s \tau^5}$
			$\frac{1}{4s\tau^6} (48 AF_3 \tau)$
			$\frac{20 AF_5}{\tau^6}$
			$\frac{1}{4s\tau^6} (80 AF_5 s)$
			$\frac{12 AH_3 s}{\tau^5}$
			$\frac{1}{4s\tau^6} (48 AH_3 s^2 \tau)$

Cuadro 1: Comparación entre salidas simbólicas de Wolfram y Python

cial en sus dos versiones (con y sin el término de *lifting* asociado a las $\widehat{D5}$ -branas). El módulo calcula además el cuadrado del gradiente, la matriz hessiana y sus autovalores, proporcionando así los elementos necesarios para evaluar la calidad de las soluciones y aplicar criterios de penalización durante el proceso de optimización.

Validación de la implementación. Para garantizar la correcta implementación del modelo, se compararon las expresiones simbólicas generadas por el código en Python con las obtenidas del código original en Mathematica (tabla 1). La correspondencia observada en la función potencial y en los elementos de la matriz jacobiana confirma que la implementación reproduce fielmente el modelo de referencia.

Experimentación preliminar con algoritmos genéticos. Una vez validada la implementación base, se sustituyó el método de optimización original por un algoritmo genético simple (SGA). Utilizando la misma base de datos de configuraciones iniciales que en Damian y Loaiza-Brito [12], se obtuvieron resultados preliminares que incluyen gráficas de convergencia y la clasificación de las soluciones en estables o inestables (según la presencia de taquiones), así como en dS o AdS (según el signo

de la energía potencial), como se muestra en la figura 1. Estos resultados constituyen un punto de referencia inicial para la comparación con otros métodos y evidencian comportamientos relevantes del espacio de soluciones.




Figura 1: Gráficas correspondientes al comportamiento del potencial efectivo. En rojo se muestra la forma sin los flujos de la D5-brana, y en azul la correspondiente al incluir dichos flujos (término de *lifting*). El diagrama de dispersión (inferior izquierda) clasifica los vacíos según el mínimo autovalor (eje x) y el valor del potencial (eje y), donde los vacíos estables dS se ubican en el cuadrante II y los vacíos estables AdS en el cuadrante IV.


Implementación de los métodos restantes. Con la infraestructura de software ya establecida, se procederá a implementar de manera secuencial los siguientes algoritmos metaheurísticos, tal como se indica en el cronograma: optimización por enjambre de partículas (PSO), algoritmos de estimación de distribución (EDAs), optimización por colonia de hormigas (ACO), optimización por maleza invasora (IWO), búsqueda de patrones (VCS) y búsqueda por sintonización adaptativa (ASO). Cada método será evaluado sobre las mismas bases de datos con el fin de garantizar la comparabilidad de los resultados.

Análisis comparativo. Finalmente, se realizará un análisis comparativo del desempeño de cada metaheurística en términos de eficiencia (número de evaluaciones requeridas para la convergencia), calidad de las soluciones (valor de la función objetivo en el mínimo encontrado) y capacidad de descubrimiento (cantidad de vacíos estables identificados). Los resultados permitirán determinar qué métodos se

adaptan mejor a la geometría del problema y si es posible incrementar el número de configuraciones estables respecto al trabajo de referencia.

2 Cronograma

A continuación el cronograma de actividades seccionada por semanas dentro del año en curso.



3 Resultados

Al final de este proyecto se obtendrá

- Tesis del proyecto investigación
- Repositorio con los códigos desarrollados durante el proyecto

Y se buscará obtener

- Participación en congreso

- Redacción y envío de artículo a revista indexada por SECIHTI
- Redacción y envío de artículo a revista indexada JCR

4 Datos SECIHTI

4.1 Metas del proyecto

La meta central del proyecto es realizar una exploración sistemática de un problema de optimización de alta dimensionalidad, derivado de un modelo específico de teoría de cuerdas tipo IIB, mediante la implementación y comparación de diversos métodos inspirados en la naturaleza (NIM, por sus siglas en inglés). Esta aproximación permite abordar el problema desde una perspectiva computacional, evaluando qué familias de algoritmos se adaptan mejor a la geometría de la función potencial considerada.

El proyecto contempla la implementación de un conjunto de NIM que incluye algoritmos genéticos, optimización por enjambre de partículas, algoritmos de estimación de distribución, colonia de hormigas, entre otros. Cada método será evaluado sobre las mismas bases de datos de configuraciones iniciales con el fin de garantizar la comparabilidad de los resultados, utilizando métricas de eficiencia computacional, calidad de las soluciones encontradas y capacidad para identificar nuevos vacíos estables no reportados previamente en la literatura.

Como producto tangible, se contempla el desarrollo de código científico, el cual será liberado como software de acceso abierto, que implemente la función objetivo y los algoritmos de optimización, constituyendo una herramienta reutilizable para la comunidad científica nacional e internacional. Asimismo, se prevé la publicación de los resultados en una revista indexada en el Sistema de Clasificación de Revistas Mexicanas de Ciencia y Tecnología de CONAHCYT, contribuyendo a la difusión del conocimiento generado.

4.2 Impacto científico del proyecto

La contribución fundamental del proyecto radica en la exploración sistemática del paisaje de vacíos en modelos de teoría de cuerdas tipo IIB mediante métodos inspirados en la naturaleza (NIM). Al optimizar una función potencial derivada de estos modelos, es posible analizar el comportamiento del espacio de soluciones en compactificaciones con torsión, así como las condiciones bajo las cuales emergen configuraciones estables. Esta aproximación computacional permite contrastar, a nivel numérico, ciertos escenarios discutidos en la literatura, tales como la posible existencia de vacíos de Sitter estables, la estructura de escalas en espacios AdS o la presencia de taquiones en el espectro.

Desde el punto de vista metodológico, la comparación del desempeño de distintos NIM (clasificados según su naturaleza como algoritmos de búsqueda individual o poblacional) sobre un problema concreto de la física teórica aporta criterios objetivos para la selección de estrategias de optimización en futuras investigaciones. En particular, se considera que no existe un método universalmente superior, ya que su eficacia depende de las características específicas del problema. La función potencial empleada presenta rasgos como alta dimensionalidad, multimodalidad

y no linealidad, comunes en diversos modelos de la física contemporánea. En este sentido, los resultados obtenidos permiten orientar la elección de estrategias de exploración global y explotación local en problemas con estructuras de búsqueda complejas.

El software científico derivado del proyecto constituirá una herramienta para futuras investigaciones, permitiendo extender, modificar y reproducir los procesos experimentales aquí desarrollados. Su disponibilidad como código abierto facilita que otros investigadores utilicen esta base para abordar problemas similares, tanto en el mismo dominio físico como en áreas afines. De este modo, el proyecto contribuye al intercambio propio de la comunidad científica mediante la generación de herramientas reproducibles y resultados verificables.

4.3 Aportación a problemas prioritarios

Las características del modelo físico tratado en este proyecto (alta dimensionalidad, múltiples óptimos locales, no linealidad y una estructura matemática compleja) son las mismas que aparecen en problemas de optimización asociados a diversos Programas Nacionales Estratégicos (PRONACES) de CONAHCYT. Por ejemplo, el diseño de redes eléctricas inteligentes y la integración de energías renovables (PRONACE 11, Transición energética y cambio climático), así como el manejo sustentable de recursos naturales y la conservación de ecosistemas (PRONACE 3, Sistemas socioambientales y sustentabilidad), requieren explorar espacios de soluciones extensos, escapar de óptimos locales y encontrar configuraciones estables. La implementación y comparación de distintas familias de métodos inspirados en la naturaleza (NIM) sobre un sistema de alta complejidad contribuye a consolidar el conocimiento metodológico necesario para abordar esta clase de problemas. Las herramientas computacionales y el análisis comparativo desarrollados en este proyecto aportan así elementos transferibles a dichos contextos, no de manera directa, sino como parte del acervo metodológico disponible para la investigación aplicada en áreas prioritarias.

Bibliografía

- [1] Qiang Du. “Some perspective on the Large Scale Scientific Computation Research”. En: *Science in China Series A: Mathematics* 47.S1 (ene. de 2004), 1-3. issn: 1862-2763. doi: 10.1007/bf02894554. url: <http://dx.doi.org/10.1007/bf02894554>.
- [2] T MCMILLAN. “SCIENTIFIC COMPUTING”. English. En: *POPULAR COMPUTING* 4.6 (1985), pág. 67. issn: 0279-4721.
- [3] Gokul Yenduri et al. “GPT (Generative Pre-Trained Transformer)— A Comprehensive Review on Enabling Technologies, Potential Applications, Emerging Challenges, and Future Directions”. En: *IEEE Access* 12 (2024), 54608-54649. issn: 2169-3536. doi: 10.1109/access.2024.3389497. url: <http://dx.doi.org/10.1109/ACCESS.2024.3389497>.
- [4] Greg Wilson et al. “Best Practices for Scientific Computing”. En: *PLoS Biology* 12.1 (ene. de 2014). Ed. por Jonathan A. Eisen, e1001745. issn: 1545-7885. doi: 10.1371/journal.pbio.1001745. url: <http://dx.doi.org/10.1371/journal.pbio.1001745>.
- [5] Xin-She Yang y Mehmet Karamanoglu. “Chapter 1 - Nature-inspired computation and swarm intelligence: a state-of-the-art overview”. En: *Nature-Inspired Computation and Swarm Intelligence*. Ed. por Xin-She Yang. Academic Press, 2020, págs. 3-18. isbn: 978-0-12-819714-1. doi: <https://doi.org/10.1016/B978-0-12-819714-1.00010-5>. url: <https://www.sciencedirect.com/science/article/pii/B9780128197141000105>.
- [6] Zhongqiang Ma et al. “Performance assessment and exhaustive listing of 500+nature-inspired metaheuristic algorithms”. English. En: *SWARM AND EVOLUTIONARY COMPUTATION* 77 (mar. de 2023). issn: 2210-6502. doi: 10.1016/j.swevo.2023.101248.
- [7] Xin-She Yang. *Nature-Inspired Algorithms and Applied Optimization*. Springer, 2017, pág. 330. url: https://openlibrary.org/books/OL27946749M/Nature-Inspired_Algorithms_and_Applied_Optimization.
- [8] A.E. Eiben y J.E. Smith. *Introduction to Evolutionary Computing*. Springer Berlin Heidelberg, 2015. isbn: 9783662448748. doi: 10.1007/978-3-662-44874-8. url: <http://dx.doi.org/10.1007/978-3-662-44874-8>.
- [9] Stefano Lanza y Alexander Westphal. “Uplifts in the penumbra: features of the moduli potential away from infinite-distance boundaries”. En: *Journal of High Energy Physics* 2025.5 (mayo de 2025). issn: 1029-8479. doi: 10.1007/jhep05(2025)071. url: [http://dx.doi.org/10.1007/JHEP05\(2025\)071](http://dx.doi.org/10.1007/JHEP05(2025)071).
- [10] G. Bruno De Luca. “Machine Learning gravity compactifications on negatively curved manifolds”. En: *Journal of High Energy Physics* 2025.9 (sep. de 2025). issn: 1029-8479. doi: 10.1007/jhep09(2025)090. url: [http://dx.doi.org/10.1007/JHEP09\(2025\)090](http://dx.doi.org/10.1007/JHEP09(2025)090).
- [11] D.H. Wolpert y W.G. Macready. “No free lunch theorems for optimization”. En: *IEEE Transactions on Evolutionary Computation* 1.1 (abr. de 1997), 67-82. issn: 1089-778X. doi: 10.1109/4235.585893. url: <http://dx.doi.org/10.1109/4235.585893>.

- [12] Cesar Damian y Oscar Loaiza-Brito. “Metastable vacua from torsion and machine learning”. En: *The European Physical Journal C* 82.12 (dic. de 2022). issn: 1434-6052. doi: 10.1140/epjc/s10052-022-11118-x. url: <http://dx.doi.org/10.1140/epjc/s10052-022-11118-x>.
- [13] Yanchao Wang et al. “Crystal structure prediction via particle-swarm optimization”. En: *Physical Review B* 82.9 (sep. de 2010). issn: 1550-235X. doi: 10.1103/physrevb.82.094116. url: <http://dx.doi.org/10.1103/PhysRevB.82.094116>.
- [14] J Prasad y T Souradeep. “Cosmological parameter estimation using Particle Swarm Optimization”. En: *Journal of Physics: Conference Series* 484 (mar. de 2014), pág. 12047. issn: 1742-6596. doi: 10.1088/1742-6596/484/1/012047. url: <http://dx.doi.org/10.1088/1742-6596/484/1/012047>.
- [15] Prisma Megantoro et al. “Optimizing reactive power dispatch with metaheuristic algorithms: A review of renewable distributed generation integration with intermittency considerations”. En: *Energy Reports* 13 (jun. de 2025), 397-423. issn: 2352-4847. doi: 10.1016/j.egyr.2024.12.020. url: <http://dx.doi.org/10.1016/j.egyr.2024.12.020>.
- [16] Steven Abel y John Rizos. “Genetic algorithms and the search for viable string vacua”. En: *Journal of High Energy Physics* 2014.8 (ago. de 2014). issn: 1029-8479. doi: 10.1007/jhep08(2014)010. url: [http://dx.doi.org/10.1007/JHEP08\(2014\)010](http://dx.doi.org/10.1007/JHEP08(2014)010).
- [17] Nana Cabo Bizet et al. “Testing swampland conjectures with machine learning”. En: *The European Physical Journal C* 80.8 (ago. de 2020). issn: 1434-6052. doi: 10.1140/epjc/s10052-020-8332-9. url: <http://dx.doi.org/10.1140/epjc/s10052-020-8332-9>.
- [18] Yang-Hui He, Vishnu Jejjala y Tomás S.R. Silva. “Metaheuristic generation of brane tilings”. En: *Physics Letters B* 862 (mar. de 2025), pág. 139365. issn: 0370-2693. doi: 10.1016/j.physletb.2025.139365. url: <http://dx.doi.org/10.1016/j.physletb.2025.139365>.
- [19] Xin Gao y Hao Zou. “Applying machine learning to the Calabi-Yau orientifolds with string vacua”. En: *Physical Review D* 105.4 (feb. de 2022). issn: 2470-0029. doi: 10.1103/physrevd.105.046017. url: <http://dx.doi.org/10.1103/PhysRevD.105.046017>.