



Campus Irapuato-Salamanca | División de Ingenierías

Propuesta de tesis

“Implementación de métodos metaheurísticos para la optimización de coeficientes de función potencial en el marco de la teoría K dentro de la teoría de cuerdas”

Presentado por: **Brandon Marquez Salazar**
b.marquezsalar@ugto.mx

Alumno dentro del programa de Maestría en Ingeniería Eléctrica (Instrumentación y Sistemas Digitales)

 Dr. Ángel Díaz Pacheco
Asesor de Proyecto

 Dr. César Eduardo Damián Ascencio
Coasesor de Proyecto

Sinodales propuestos

- ✦ Dr. Carlos Hugo García Capulín
- ✦ Dr. Juan Pablo Ignacio Ramírez Paredes
- ✦ Dra. Dora Luz Almanza Ojeda
- ✦ Dr. Mario Alberto Ibarra Manzano
- ✦ Dr. Juan Carlos Gomez Carranza



Índice general

1	Introducción	2
1.1	Objetivos	2
1.1.1	Objetivo general	2
1.1.2	Objetivos específicos	2
1.2	Justificación	3
1.3	Antecedentes	3
1.3.1	NIM en la investigación	3
1.3.2	Aplicaciones metaheurísticas en la exploración de configuraciones de vacío	4
1.4	Desarrollo	5
2	Cronograma	7
3	Resultados	7
4	Datos SECIHTI	7
4.1	Metas del proyecto	7
4.2	Impacto científico del proyecto	8
4.3	Aportación a problemas prioritarios	9
	Bibliografía	10



1 Introducción

El uso de herramientas computacionales ha tenido un impacto significativo dentro de la investigación científica [1]. Dicho impacto abarca desde el desarrollo de sistemas simples de tareas de automatización y gestión de datos [2], hasta modernas aproximaciones de inteligencia artificial basada en tensores [3, 4], pasando por herramientas de *Machine Learning* (ML).

En este contexto, los métodos inspirados en la naturaleza (*Nature-Inspired Methods*, NIM) han emergido como una alternativa robusta para resolver problemas de optimización donde los métodos analíticos tradicionales resultan insuficientes. Estos algoritmos se basan en el comportamiento de seres vivos, procesos físicos, interacciones químicas, entre otros [5, 6].

Las metaheurísticas, en particular, implementan reglas locales simples para dar lugar a comportamientos complejos. Su principal ventaja radica en la capacidad de equilibrar la exploración de nuevas regiones con la explotación de soluciones prometedoras, permitiendo encontrar óptimos en modelos cuya estructura subyacente o función de costo es desconocida o altamente no lineal [5, 7].

Este tipo de implementaciones permiten encontrar soluciones en modelos cuyo comportamiento es desconocido. Tal como se menciona en [8], la optimización consiste en la búsqueda de valores de entrada óptimos para un modelo.

Un caso crítico de aplicación se encuentra en la exploración de paisajes de soluciones (*landscapes*) derivados de modelos de física teórica, como la teoría de cuerdas. Computacionalmente, estos problemas se traducen en la búsqueda de mínimos estables dentro de un hiperespacio de parámetros de gran magnitud. Debido al comportamiento caótico y la presencia de múltiples óptimos locales, la implementación de metaheurísticas se presenta como un recurso computacional valioso para guiar la búsqueda hacia configuraciones estables de manera eficiente.

1.1 Objetivos

1.1.1 Objetivo general

Implementar diversos NIM para la optimización de los coeficientes de una función potencial en el marco de la K-teoría dentro de la teoría de cuerdas, con el fin de identificar y caracterizar una mayor cantidad de vacíos estables.

1.1.2 Objetivos específicos

- ✦ Analizar los fundamentos teóricos de la K-teoría en teoría de cuerdas, con énfasis en la formulación de la función potencial y la noción de vacíos estables.
- ✦ Revisar y seleccionar métodos metaheurísticos adecuados (algoritmos genéticos, optimización por enjambre de partículas, algoritmos de estimación de distribución, colonia de hormigas, entre otros) para el problema planteado.
- ✦ Modelar el problema de optimización de los coeficientes de la función potencial como un problema computacional tratable mediante técnicas metaheurísticas.



- ✦ Implementar los métodos seleccionados y adaptar sus parámetros para su aplicación en el contexto del problema.
- ✦ Evaluar el desempeño de los métodos mediante métricas de convergencia, calidad de solución y capacidad para identificar vacíos estables.
- ✦ Comparar los resultados obtenidos con enfoques existentes o configuraciones base, a fin de determinar mejoras en la cantidad y calidad de los vacíos encontrados.

1.2 Justificación

La exploración de configuraciones de vacío en teoría de cuerdas constituye un problema de optimización en espacios de alta dimensionalidad, donde las funciones de energía potencial presentan múltiples óptimos locales y regiones caóticas que dificultan el uso de métodos analíticos tradicionales o gradiente-dependientes [9, 10]. En este contexto, las metaheurísticas ofrecen una alternativa natural para abordar la búsqueda sistemática de puntos estables.

En optimización computacional, el teorema de *No Free Lunch* (NFL) establece que no existe un algoritmo universalmente superior para todos los problemas [11]. El desempeño relativo de los métodos depende fuertemente de las características específicas del problema abordado. Para el caso de la optimización de funciones potenciales derivadas de la K-teoría, no existe garantía *a priori* de que un método particular sea la estrategia más adecuada en términos de eficiencia, precisión o capacidad de exploración.

Por tanto, resulta pertinente explorar un conjunto amplio de metaheurísticas (algoritmos genéticos, optimización por enjambre de partículas, algoritmos de estimación de distribución, colonia de hormigas, entre otros) para determinar cuáles se adaptan mejor a la geometría del problema. La importancia de este proyecto radica en lograr una mejora en el método de búsqueda: al implementar y evaluar múltiples enfoques, se busca incrementar la cantidad de vacíos estables identificados respecto a trabajos previos como [12], ampliando el catálogo de configuraciones conocidas y contribuyendo a una comprensión más completa del paisaje de soluciones.

1.3 Antecedentes

1.3.1 NIM en la investigación

El ámbito de la investigación de alto rigor, como el que caracteriza a la química o la cosmología, suele asociarse con métodos matemáticos formalmente fundamentados. Sin embargo, en las últimas décadas, los métodos metaheurísticos han irrumpido en estos campos con resultados notables. Su aplicación ha permitido demostrar que, a pesar de carecer de la formalidad matemática teórica que tradicionalmente se exige en estas disciplinas, resultan ser herramientas perfectamente aplicables y, en muchos contextos, altamente efectivas [13, 14].

Esta efectividad se traduce en logros concretos: una reducción sustancial del coste computacional y, cuando el modelo está bien sintonizado y la función objetivo correctamente definida, una precisión superior gracias a sus capacidades de



explotación, llegando incluso a superar los valores obtenidos mediante enfoques tradicionales [15].

1.3.2 Aplicaciones metaheurísticas en la exploración de configuraciones de vacío

El uso de metaheurísticas para explorar el espacio de configuraciones en teoría de cuerdas ha demostrado mejoras significativas en eficiencia, capacidad de descubrimiento y precisión respecto a los métodos de búsqueda aleatoria. A continuación se reseñan los principales avances agrupados por las cualidades que dichas técnicas han evidenciado.

Eficiencia en la búsqueda El trabajo pionero de Abel y Rizos [16] estableció que los algoritmos genéticos son órdenes de magnitud más eficientes que el escaneo aleatorio para localizar configuraciones con propiedades fenomenológicas específicas dentro de modelos fermiónicos libres. Este resultado fue relevante para demostrar que, aunque el espacio de búsqueda es inmenso (del orden de 2^{51} configuraciones posibles), la estructura del paisaje permite que métodos guiados por selección y cruce converjan rápidamente hacia regiones de interés.

Posteriormente, el trabajo de Bizet et al. [17] reportó más de sesenta mil configuraciones de flujo con puntos críticos en compactificaciones Tipo IIB, empleando un algoritmo genético acoplado a una red neuronal. Este enfoque híbrido permitió reducir drásticamente el tiempo de cómputo respecto a la fuerza bruta, evidenciando que la sinergia entre metaheurísticas y aprendizaje automático puede escalar la exploración a espacios de mayor complejidad.

Capacidad de descubrimiento y generación de nuevas configuraciones Más allá de la búsqueda eficiente, las metaheurísticas han demostrado capacidad para generar configuraciones novedosas no reportadas previamente. [18] utilizó templado simulado (*simulated annealing*) para construir *brane tilings* geoméricamente consistentes, logrando descubrir un nuevo *tiling* con 26 campos cuánticos que no aparecía en catálogos exhaustivos previos. Este trabajo evidencia que las metaheurísticas no solo optimizan dentro de espacios conocidos, sino que pueden explorar regiones inéditas del espacio de soluciones.

Precisión y calidad de las soluciones En el ámbito de la clasificación geométrica, [19] alcanzó precisiones superiores al 99.9% en la predicción de politopos que conducen a orientifolds de Calabi-Yau y vacíos Tipo IIB. Aunque su enfoque principal es una red neuronal convolucional, el proceso de entrenamiento y validación cruzada demuestra que los métodos computacionales pueden capturar patrones sutiles en los datos de entrada (las coordenadas de los politopos) y traducirlos en predicciones de alta calidad sobre la viabilidad de las configuraciones resultantes.

Exploración de regiones de transición Un avance particularmente relevante para el problema de optimización de potenciales es el reportado por [9]. Mediante técnicas de aprendizaje automático, los autores identificaron regiones de "penumbra"



(zonas de transición entre el interior del espacio de módulos y sus límites asintóticos) donde aparecen configuraciones metaestables con energía positiva. Aunque su enfoque no es puramente metaheurístico, el trabajo demuestra que dichas regiones albergan estructuras finas del potencial que son susceptibles de ser exploradas mediante métodos de optimización global.

Contexto metodológico complementario Finalmente, [10] abordó el problema desde una perspectiva numérica diferente: la resolución directa de ecuaciones diferenciales parciales mediante redes neuronales. Si bien no emplea metaheurísticas, su trabajo contextualiza la necesidad de métodos computacionales robustos para atacar problemas geométricos en compactificaciones, y establece un punto de comparación respecto a enfoques alternativos para construir métricas y configuraciones de vacío.

Hacia una extensión del enfoque Los trabajos aquí reseñados muestran una tendencia clara: el uso de metaheurísticas permite explorar eficientemente el paisaje de vacíos. En particular, [12] implementó templado simulado para identificar más de 170 configuraciones dS estables en compactificaciones Tipo IIB con torsión, demostrando la viabilidad del método. No obstante, dicho estudio se limitó a un único algoritmo estocástico. El presente trabajo se propone extender este análisis mediante la implementación y comparación de un conjunto más amplio de metaheurísticas, con el fin de evaluar su desempeño relativo y determinar si es posible incrementar la cantidad de vacíos estables identificados respecto a lo reportado en [12].

1.4 Desarrollo

El desarrollo del proyecto se ha estructurado en etapas que responden a los objetivos planteados y al cronograma establecido.

Análisis del modelo base. Se realizó ingeniería inversa del código original en Mathematica proporcionado por [12], identificando la función potencial, sus descriptores (cuadrado del gradiente, matriz hessiana, autovalores) y la lógica del método de optimización empleado originalmente (templado simulado con refinamiento por gradiente conjugado). Este análisis permitió extraer las expresiones simbólicas que rigen el modelo.

Implementación simbólica en Python. Con base en las expresiones obtenidas, se desarrolló un módulo en Python que utiliza sympy para definir la función potencial en sus dos versiones (con y sin el término de lifting asociado a las $\widehat{D5}$ -branas). El módulo calcula también el cuadrado del gradiente, la matriz hessiana y sus autovalores, proporcionando así todos los elementos necesarios para evaluar la calidad de las soluciones y aplicar los criterios de penalización durante la optimización.

Validación de la implementación. Para garantizar la correcta interpretación del modelo, se compararon manualmente las expresiones simbólicas generadas por el



código en Python con las del código original en Mathematica. La correspondencia obtenida para la función potencial y los elementos de la matriz jacobiana confirma que la implementación es fiel al modelo de referencia.


Experimentación preliminar con algoritmos genéticos. Una vez validada la implementación base, se sustituyó el método de optimización original por un algoritmo genético simple (SGA). Utilizando la misma base de datos de configuraciones iniciales que en [12], se obtuvieron resultados preliminares que incluyen gráficas de convergencia y la clasificación de las soluciones en estables o inestables (según la presencia de taquiones) y en dS o AdS (según el signo de la energía potencial). Estos resultados sirven como punto de partida para la comparación con otros métodos. Además de haber arrojado elementos interesantes y relevantes a la búsqueda.

Implementación de los métodos restantes. Con la infraestructura de software ya establecida, se procederá a implementar secuencialmente los siguientes algoritmos metaheurísticos, tal como se indica en el cronograma: optimización por enjambre de partículas (PSO), algoritmos de estimación de distribución (EDAs), optimización por colonia de hormigas (ACO), optimización por maleza invasora (IWO), búsqueda de patrones (VCS) y búsqueda por sintonización adaptativa (ASO). Cada método se evaluará sobre las mismas bases de datos para garantizar la comparabilidad de los resultados.

Análisis comparativo. Finalmente, se realizará un análisis comparativo del desempeño de cada metaheurística en términos de eficiencia (número de evaluaciones necesarias para converger), calidad de las soluciones (valor de la función objetivo en el mínimo encontrado) y capacidad de descubrimiento (cantidad de vacíos estables identificados). Los resultados permitirán determinar cuáles métodos se adaptan mejor a la geometría del problema y si es posible incrementar el número de configuraciones estables reportadas respecto al trabajo de referencia.



2 Cronograma



3 Resultados

Al final de este proyecto se obtendrá

✿ Tesis del proyecto investigación

Y se buscará obtener

✿ Participación en congreso

✿ Publicación de artículo en revista indexada por SECIHTI

✿ Publicación de artículo en revista indexada JCR

4 Datos SECIHTI

4.1 Metas del proyecto

La meta central del proyecto es realizar una exploración sistemática de un problema de optimización de alta dimensionalidad (derivado de un modelo de teoría



de cuerdas tipo IIB) mediante la implementación y comparación de diversos métodos inspirados en la naturaleza (NIM, por sus siglas en inglés). Esta aproximación permite abordar el problema desde una perspectiva computacional, evaluando qué familias de algoritmos se adaptan mejor a la geometría particular de una función potencial proveniente de la K-teoría.

El proyecto contempla la implementación de un conjunto de NIM que incluye algoritmos genéticos, optimización por enjambre de partículas, algoritmos de estimación de distribución, colonia de hormigas, entre otros. Cada método será evaluado sobre las mismas bases de datos de configuraciones iniciales para garantizar la comparabilidad de los resultados, utilizando métricas de eficiencia computacional, calidad de las soluciones encontradas y capacidad para identificar nuevos vacíos estables no reportados previamente en la literatura.

En cuanto a la formación de recursos humanos, el proyecto contribuye al desarrollo de capacidades en modelado matemático avanzado, optimización computacional, manejo de herramientas de cálculo simbólico y programación científica. Estas competencias, al ser transferibles a otras áreas de la ciencia y la ingeniería, inciden en la consolidación de capital humano especializado en métodos computacionales aplicados a problemas de ciencia básica y de frontera.

Como producto tangible, se espera generar código científico (liberado como software de acceso abierto) que implementa la función objetivo y los algoritmos de optimización, constituyendo una herramienta reusable para la comunidad científica nacional e internacional. Asimismo, se buscará publicar los resultados en una revista indexada en el Sistema de Clasificación de Revistas Mexicanas de Ciencia y Tecnología de CONAHCYT, contribuyendo de esta manera a la difusión del conocimiento generado en el país.

4.2 Impacto científico del proyecto

La contribución fundamental del proyecto radica en la exploración sistemática del paisaje de vacíos en teoría de cuerdas tipo IIB mediante métodos inspirados en la naturaleza (NIM). Al optimizar una función potencial derivada de la K-teoría, es posible comprender mejor el comportamiento del espacio de soluciones en compactificaciones con torsión, así como las condiciones bajo las cuales emergen configuraciones estables. Esta aproximación computacional permite contrastar, a nivel numérico, predicciones derivadas del programa Swampland, tales como la (in)existencia de vacíos de Sitter estables, la separación de escalas en espacios AdS, o las condiciones para la presencia de taquiones en el espectro.

Desde el punto de vista metodológico, la comparación del desempeño de distintos NIM (clasificados según su naturaleza como algoritmos de búsqueda única o múltiple) sobre un problema concreto de la física teórica aporta criterios objetivos para la selección de estrategias de optimización en futuras investigaciones. En particular, se parte del hecho de que no existe un método universalmente superior; su eficacia relativa depende de las características del problema abordado. La función potencial empleada presenta rasgos (alta dimensionalidad, múltiples óptimos locales, no linealidad) que son comunes a otros modelos de la física contemporánea. Así, la experiencia adquirida en este estudio permite una toma de decisiones más informada en problemas que requieran exploración amplia o explotación de regiones prometedoras, según la naturaleza del espacio de búsqueda.



El software científico derivado del proyecto constituirá una herramienta para futuras investigaciones, permitiendo extender, modificar y reproducir los procesos experimentales aquí desarrollados. Su disponibilidad como código abierto posibilita que otros investigadores se apoyen en esta base para abordar problemas similares, ya sea en el mismo dominio físico o en áreas afines. De este modo, el proyecto participa del intercambio propio de la comunidad científica a través de la utilidad concreta de sus productos, que quedan expuestos a la replicación y el escrutinio.

4.3 Aportación a problemas prioritarios

Las características del modelo físico tratado en este proyecto (alta dimensionalidad, múltiples óptimos locales, no linealidad y una estructura matemática compleja) son las mismas que aparecen en problemas de optimización asociados a diversos Programas Nacionales Estratégicos (PRONACES) de CONAHCYT. Por ejemplo, el diseño de redes eléctricas inteligentes y la integración de energías renovables (PRONACE 11, Transición energética y cambio climático), así como el manejo sustentable de recursos naturales y la conservación de ecosistemas (PRONACE 3, Sistemas socioambientales y sustentabilidad), requieren explorar espacios de soluciones extensos, escapar de óptimos locales y encontrar configuraciones estables. La implementación y comparación de distintas familias de métodos inspirados en la naturaleza (NIM) sobre un sistema de alta complejidad contribuye a consolidar el conocimiento metodológico necesario para abordar esta clase de problemas. Las herramientas computacionales y el análisis comparativo desarrollados en este proyecto aportan así elementos transferibles a dichos contextos, no de manera directa, sino como parte del acervo metodológico disponible para la investigación aplicada en áreas prioritarias.



Bibliografía

- [1] Qiang Du. "Some perspective on the Large Scale Scientific Computation Research". En: *Science in China Series A: Mathematics* 47.S1 (ene. de 2004), 1-3. issn: 1862-2763. doi: 10.1007/bf02894554. url: <http://dx.doi.org/10.1007/bf02894554>.
- [2] T MCMILLAN. "SCIENTIFIC COMPUTING". English. En: *POPULAR COMPUTING* 4.6 (1985), pág. 67. issn: 0279-4721.
- [3] Gokul Yenduri et al. "GPT (Generative Pre-Trained Transformer)— A Comprehensive Review on Enabling Technologies, Potential Applications, Emerging Challenges, and Future Directions". En: *IEEE Access* 12 (2024), 54608-54649. issn: 2169-3536. doi: 10.1109/access.2024.3389497. url: <http://dx.doi.org/10.1109/ACCESS.2024.3389497>.
- [4] Greg Wilson et al. "Best Practices for Scientific Computing". En: *PLoS Biology* 12.1 (ene. de 2014). Ed. por Jonathan A. Eisen, e1001745. issn: 1545-7885. doi: 10.1371/journal.pbio.1001745. url: <http://dx.doi.org/10.1371/journal.pbio.1001745>.
- [5] Xin-She Yang y Mehmet Karamanoglu. "Chapter 1 - Nature-inspired computation and swarm intelligence: a state-of-the-art overview". En: *Nature-Inspired Computation and Swarm Intelligence*. Ed. por Xin-She Yang. Academic Press, 2020, págs. 3-18. isbn: 978-0-12-819714-1. doi: <https://doi.org/10.1016/B978-0-12-819714-1.00010-5>. url: <https://www.sciencedirect.com/science/article/pii/B9780128197141000105>.
- [6] Zhongqiang Ma et al. "Performance assessment and exhaustive listing of 500+nature-inspired metaheuristic algorithms". English. En: *SWARM AND EVOLUTIONARY COMPUTATION* 77 (mar. de 2023). issn: 2210-6502. doi: 10.1016/j.swevo.2023.101248.
- [7] Xin-She Yang. *Nature-Inspired Algorithms and Applied Optimization*. Springer, 2017, pág. 330. url: https://openlibrary.org/books/OL27946749M/Nature-Inspired_Algorithms_and_Applied_Optimization.
- [8] A.E. Eiben y J.E. Smith. *Introduction to Evolutionary Computing*. Springer Berlin Heidelberg, 2015. isbn: 9783662448748. doi: 10.1007/978-3-662-44874-8. url: <http://dx.doi.org/10.1007/978-3-662-44874-8>.
- [9] Stefano Lanza y Alexander Westphal. "Uplifts in the penumbra: features of the moduli potential away from infinite-distance boundaries". En: *Journal of High Energy Physics* 2025.5 (mayo de 2025). issn: 1029-8479. doi: 10.1007/jhep05(2025)071. url: [http://dx.doi.org/10.1007/JHEP05\(2025\)071](http://dx.doi.org/10.1007/JHEP05(2025)071).
- [10] G. Bruno De Luca. "Machine Learning gravity compactifications on negatively curved manifolds". En: *Journal of High Energy Physics* 2025.9 (sep. de 2025). issn: 1029-8479. doi: 10.1007/jhep09(2025)090. url: [http://dx.doi.org/10.1007/JHEP09\(2025\)090](http://dx.doi.org/10.1007/JHEP09(2025)090).
- [11] D.H. Wolpert y W.G. Macready. "No free lunch theorems for optimization". En: *IEEE Transactions on Evolutionary Computation* 1.1 (abr. de 1997), 67-82. issn: 1089-778X. doi: 10.1109/4235.585893. url: <http://dx.doi.org/10.1109/4235.585893>.



- [12] Cesar Damian y Oscar Loaiza-Brito. “Metastable vacua from torsion and machine learning”. En: *The European Physical Journal C* 82.12 (dic. de 2022). issn: 1434-6052. doi: 10.1140/epjc/s10052-022-11118-x. url: <http://dx.doi.org/10.1140/epjc/s10052-022-11118-x>.
- [13] Yanchao Wang et al. “Crystal structure prediction via particle-swarm optimization”. En: *Physical Review B* 82.9 (sep. de 2010). issn: 1550-235X. doi: 10.1103/physrevb.82.094116. url: <http://dx.doi.org/10.1103/PhysRevB.82.094116>.
- [14] J Prasad y T Souradeep. “Cosmological parameter estimation using Particle Swarm Optimization”. En: *Journal of Physics: Conference Series* 484 (mar. de 2014), pág. 12047. issn: 1742-6596. doi: 10.1088/1742-6596/484/1/012047. url: <http://dx.doi.org/10.1088/1742-6596/484/1/012047>.
- [15] Prisma Megantoro et al. “Optimizing reactive power dispatch with metaheuristic algorithms: A review of renewable distributed generation integration with intermittency considerations”. En: *Energy Reports* 13 (jun. de 2025), 397-423. issn: 2352-4847. doi: 10.1016/j.egyr.2024.12.020. url: <http://dx.doi.org/10.1016/j.egyr.2024.12.020>.
- [16] Steven Abel y John Rizos. “Genetic algorithms and the search for viable string vacua”. En: *Journal of High Energy Physics* 2014.8 (ago. de 2014). issn: 1029-8479. doi: 10.1007/jhep08(2014)010. url: [http://dx.doi.org/10.1007/JHEP08\(2014\)010](http://dx.doi.org/10.1007/JHEP08(2014)010).
- [17] Nana Cabo Bizet et al. “Testing swampland conjectures with machine learning”. En: *The European Physical Journal C* 80.8 (ago. de 2020). issn: 1434-6052. doi: 10.1140/epjc/s10052-020-8332-9. url: <http://dx.doi.org/10.1140/epjc/s10052-020-8332-9>.
- [18] Yang-Hui He, Vishnu Jejjala y Tomás S.R. Silva. “Metaheuristic generation of brane tilings”. En: *Physics Letters B* 862 (mar. de 2025), pág. 139365. issn: 0370-2693. doi: 10.1016/j.physletb.2025.139365. url: <http://dx.doi.org/10.1016/j.physletb.2025.139365>.
- [19] Xin Gao y Hao Zou. “Applying machine learning to the Calabi-Yau orientifolds with string vacua”. En: *Physical Review D* 105.4 (feb. de 2022). issn: 2470-0029. doi: 10.1103/physrevd.105.046017. url: <http://dx.doi.org/10.1103/PhysRevD.105.046017>.

